

Praca magisterska - Porównanie i analiza modeli
Speech To Text v1.25.05.2

Marcel Zieliński

Contents

Unnumbered Section	4
1 Wstęp	5
1.1 Uzasadnienie wyboru tematu	5
1.2 Cel i zakres pracy	5
1.3 Metodyka badań i narzędzia	7
1.4 Struktura pracy	7
2 Teoretyczne podstawy technologii Speech-to-Text	7
2.1 Wprowadzenie do technologii rozpoznawania mowy	7
2.2 Ewolucja systemów ASR (Automatic Speech Recognition)	7
2.3 Kluczowe pojęcia: fonemy, modele akustyczne, modele językowe	7
2.4 Metody uczenia modeli STT (HMM, DNN, Transformer, Whisper)	7
2.5 Standardy i protokoły wykorzystywane w systemach STT	7
2.6 Wyzwania technologiczne: szumy, akcenty, kontekst, modele on-device	7
3 Implementacja metody i badań	7
3.1 Przegląd dostępnych narzędzi i usług Speech-to-Text	7
3.2 Kryteria porównawcze narzędzi STT	7
3.3 Google Speech-to-Text API	7
3.4 Microsoft Azure Speech Service	7
3.5 Amazon Transcribe	7
3.6 OpenAI Whisper (on-device i w chmurze)	7
3.7 Web Speech API (przeglądarkowe)	7
3.8 Porównanie dostępnych narzędzi:	7
3.8.1 Dokładność transkrypcji	7
3.8.2 Opóźnienia i czas przetwarzania	7
3.8.3 Wymagania sprzętowe	7
3.8.4 Koszty użytkowania	7
3.8.5 Możliwość pracy offline	7
3.8.6 Dostępność języka polskiego	7
4 Technologia React jako platforma implementacji	7
4.1 Architektura React – komponenty, hooki, state management	7
4.2 Integracja z API i usługami zewnętrznymi	7
5 Projekt i implementacja aplikacji React wykorzystującej Speech-to-Text	7
5.1 Założenia funkcjonalne aplikacji	7
5.2 Projekt architektury systemu	7
5.2.1 Ogólny schemat przepływu danych	7
5.2.2 Integracja z wybranymi usługami STT	7
5.2.3 Warstwa frontendu (React)	7
5.2.4 Ewentualna warstwa backendowa (FastAPI)	7

5.3	Implementacja modułu nagrywania dźwięku	7
5.4	Implementacja komunikacji z API STT	7
5.5	Wizualizacja i edycja transkrypcji	7
5.6	Obsługa błędów i fallbacki (np. Whisper offline)	7
5.7	Testy funkcjonalne i wydajnościowe	7
5.8	Wyzwania implementacyjne i sposoby ich rozwiązania	7
6	Studium porównawcze skuteczności wybranych narzędzi STT	7
6.1	Projekt eksperymentu	7
6.1.1	Przygotowanie zestawu nagrań	7
6.1.2	Warunki badania i pomiarów	7
6.2	Metryki oceny jakości transkrypcji (WER, CER, RTT)	7
6.3	Wyniki testów porównawczych	7
6.4	Analiza statystyczna wyników	7
6.5	Wnioski z badań	7
7	Ocena przydatności technologii STT w aplikacjach webowych	7
7.1	Zastosowania praktyczne	7
7.2	Skalowalność i efektywność kosztowa	7
7.3	Bezpieczeństwo i prywatność danych audio	7
7.4	Rekomendacje implementacyjne	7
7.5	Ograniczenia i możliwe kierunki rozwoju	7
8	Zakończenie	7
8.1	Podsumowanie pracy	7
8.2	Najważniejsze osiągnięcia	7
8.3	Kierunki dalszych badań	7

Unnumbered Section

sekcja

Cytat przykładowy [5].

1 Wstęp

1.1 Uzasadnienie wyboru tematu

Technologie Speech-to-Text (STT) coraz częściej stają się elementem interfejsów użytkownika w aplikacjach webowych, mobilnych i asystenckich. W praktyce oznacza to, że dokładność transkrypcji, czas odpowiedzi oraz odporność na zakłócenia mają bezpośredni wpływ na komfort użytkownika i przydatność całego systemu. Szczególnie istotne jest to w przypadku języka polskiego, dla którego dostępność dopracowanych rozwiązań jest nadal mniejsza niż dla języka angielskiego, a wyniki badań wskazują na duże zróżnicowanie jakości pomiędzy poszczególnymi modelami i usługami [5, 3, 2].

Temat pracy jest uzasadniony z perspektywy praktycznej, naukowej i metodologicznej. Z perspektywy praktycznej rośnie potrzeba projektowania aplikacji webowych działających w czasie rzeczywistym, w których rozpoznawanie mowy może wspierać na przykład dyktowanie, obsługę systemów bez użycia klawiatury oraz szybkie prototypowanie interfejsów głosowych. Z perspektywy naukowej nadal widoczna jest luka badawcza dotycząca porównań rozwiązań STT dla języka polskiego w warunkach zbliżonych do rzeczywistych aplikacji webowych, z uwzględnieniem zarówno modeli offline, jak i usług chmurowych oraz natywnych mechanizmów przeglądarkowych. Z perspektywy metodologicznej temat pozwala połączyć implementację systemu eksperymentalnego z obiektywną oceną jakości i wydajności, co czyni go dobrym materiałem do pracy inżyniersko-badawczej [1, 4].

W literaturze coraz częściej pojawiają się analizy porównawcze rozwiązań STT, jednak wiele z nich koncentruje się na innych językach, na modelach uruchamianych poza przeglądarką albo na jednym wybranym aspekcie jakości. W przypadku języka polskiego szczególnie wartościowe jest zestawienie rozwiązań działających lokalnie i w chmurze w jednym, powtarzalnym środowisku testowym, ponieważ dopiero takie podejście pozwala realnie ocenić ich przydatność do zastosowań webowych.

1.2 Cel i zakres pracy

Celem głównym pracy jest przeprowadzenie porównawczej analizy technologii Speech-to-Text pod kątem ich użyteczności w webowych aplikacjach real-time dla języka polskiego. Analiza obejmuje zarówno jakość transkrypcji, jak i zachowanie systemów w warunkach zbliżonych do praktycznego użycia, czyli przy zmiennym poziomie zakłóceń, różnym tempie mówienia oraz odmiennych charakterystykach głosów.

Cele szczegółowe obejmują ocenę dokładności transkrypcji z wykorzystaniem metryk WER oraz CER, pomiar opóźnień przetwarzania w ujęciu RTT, badanie odporności rozwiązań na szum i zróżnicowane warunki wejściowe, a także przy-

gotowanie webowej aplikacji eksperymentalnej umożliwiającej wykonywanie porównywalnych testów. W ramach pracy zakłada się porównanie kilku klas rozwiązań, w tym mechanizmów dostępnych w przeglądarce, komercyjnych API chmurowych oraz modeli opartych na uczeniu głębokim, takich jak Whisper.

Hipoteza badawcza zakłada, że modele oparte na uczeniu głębokim, w szczególności rozwiązania takie jak OpenAI Whisper, zapewniają wyższą dokładność transkrypcji niż komercyjne API chmurowe, jednak mogą ustępować im pod względem opóźnień potrzebnych do działania w czasie rzeczywistym. Zakres pracy obejmuje zatem nie tylko analizę jakościową wyników, ale również ocenę praktycznej przydatności badanych technologii w kontekście wdrożenia webowego.

- 1.3 Metodyka badań i narzędzia
- 1.4 Struktura pracy
- 2 Teoretyczne podstawy technologii Speech-to-Text
 - 2.1 Wprowadzenie do technologii rozpoznawania mowy
 - 2.2 Ewolucja systemów ASR (Automatic Speech Recognition)
 - 2.3 Kluczowe pojęcia: fonemy, modele akustyczne, modele językowe
 - 2.4 Metody uczenia modeli STT (HMM, DNN, Transformer, Whisper)
 - 2.5 Standardy i protokoły wykorzystywane w systemach STT
 - 2.6 Wyzwania technologiczne: szумы, akcenty, kontekst, modele on-device
- 3 Implementacja metody i badań
 - 3.1 Przegląd dostępnych narzędzi i usług Speech-to-Text
 - 3.2 Kryteria porównawcze narzędzi STT
 - 3.3 Google Speech-to-Text API
 - 3.4 Microsoft Azure Speech Service
 - 3.5 Amazon Transcribe
 - 3.6 OpenAI Whisper (on-device i w chmurze)
 - 3.7 Web Speech API (przeglądarkowe)
 - 3.8 Porównanie dostępnych narzędzi:
 - 3.8.1 Dokładność transkrypcji
 - 3.8.2 Opóźnienia i czas przetwarzania
 - 3.8.3 Wymagania sprzętowe
 - 3.8.4 Koszty użytkowania
 - 3.8.5 Możliwość pracy offline
 - 3.8.6 Dostępność języka polskiego
- 4 Technologia React jako platforma implementacji
 - 4.1 Architektura React – komponenty, hooki, state management
 - 4.2 Integracja z API i usługami zewnętrznymi
- 5 Projekt i implementacja aplikacji React wykorzystującej Speech-to-Text

References

- [1] W. Chlewicki, M. Jarząbkowski, and Katarzyna Cichoń. Potencjał zastosowania aplikacji mobilnych z usługami rozpoznawania mowy w chmurze do wspomaganie osób z upośledzonym wzrokiem. *Inżynier i Fizyk Medyczny*, 2024.
- [2] Antonino Ferraro, Antonio Galli, Valerio La Gatta, and Marco Postiglione. Benchmarking open source and paid services for speech to text: an analysis of quality and input variety. *Frontiers in Big Data*, 6:1210559, 2023.
- [3] Karolina Pondel-Sycz, Agnieszka Paula Pietrzak, and Julia Szymła. End-To-End deep neural models for Automatic Speech Recognition for polish language. *International Journal of Electronics and Telecommunications*, 70(2):315–321, 2024.
- [4] Mikołaj Pudo. *Methods of optimizing models and algorithms for automatic speech recognition in mobile applications*. PhD thesis, Warsaw University of Technology, Warsaw, Poland, 2024. Doctoral dissertation.
- [5] Marta Zielonka, Wiktor Krasiński, Jakub Nowak, Przemysław Rośleń, Jan Stopiński, Mateusz Żak, Franciszek Górski, and Andrzej Czyżewski. A survey of automatic speech recognition deep models performance for polish medical terms. In *2023 Signal Processing: Algorithms, Architectures, Arrangements, and Applications (SPA)*, pages 19–24. IEEE, 2023.